编号：

哈尔滨工业大学(威海)
大一年度项目计划立项报告

项目名称： 端侧可部署的双臂操作算法

项目负责人： 陈益博 **学号：** 202521245

联系电话： 18474615120 **电子邮箱：** cyb2831173936@163.com

院系及专业： 计算机科学与技术学院（软件工程）

指导教师： 戚兆波 **职称：** 副教授

联系电话： 18810217865 **电子邮箱：** qizb@hit.edu.cn

院系及专业： 计算机科学与技术学院

哈尔滨工业大学（威海）教务处制表

填表日期：2025 年 12 月 29 日

一、项目团队成员（包括项目负责人、按顺序）

姓名	性别	所在院	学号	身份证号	本人签字
陈益博	男	计算机科学与技术学院	2025212457	431128200608050057	
王向	男	计算机科学与技术学院	2025210427	320281200701262274	
张博	男	计算机科学与技术学院	2025212636	23092120070228001X	
薛靖萱	男	计算机科学与技术学院	2025210277	220721200709103611	
薛松	男	计算机科学与技术学院	2025212961	341181200711170612	

二、指导教师意见

签　　名：

年　　月　　日

三、项目专家组意见

批准经费：　　元　　组长签名：　　（ 教务处盖章 ）

年　　月　　日

立项报告

（一）立项背景（研究现状、趋势、研究意义等）

1.1 研究背景与意义

1.1.1 具身智能：从“看图说话”到“手眼协同”的范式转移

人工智能的发展正经历着从互联网 AI（Internet AI）向具身智能（Embodied AI）的深刻转型。传统的深度学习模型，如 ChatGPT 或 Midjourney，主要处理虚拟世界中的文本与图像数据，缺乏与物理世界进行实体交互的能力。具身智能则强调智能体（Agent）不仅要具备感知能力（Perceive），更要具备在复杂、多模态环境中进行物理动作（Act）并预测动作后果（Predict）的能力。

在这一宏大图景中，双臂机器人（Bimanual Robots）扮演着至关重要的角色。相比于单臂机器人，双臂系统并非简单的线性叠加，而是引入了复杂的协同约束与操作空间。然而，传统的双臂控制算法往往依赖于精确的数学建模和刚性的轨迹规划，难以适应非结构化的现实环境（如家庭厨房、杂乱的仓库）。

近年来，基础模型（Foundation Models）的爆发为机器人学习带来了新的曙光。视觉-语言-动作（VLA）模型通过将大语言模型（LLM）的逻辑推理能力与视觉编码器（Vision Encoder）的感知能力相结合，能够直接将自然语言指令（如“把红色的积木放到篮子里”）映射为机器人的底层控制信号。

1.1.2 “端侧部署”的现实挑战：算力与智能的博弈

尽管 VLA 模型描绘了通用的机器人未来，但其落地应用正面临着严峻的“最后一公里”挑战——端侧部署。

当前最先进的 VLA 模型（如 Google 的 RT-2）通常拥有数百亿的参数量。在学术研究中，这些模型往往运行在昂贵的服务器集群上。然而，在实际场景中，机器人自带的计算单元通常是资源受限的嵌入式设备（如笔记本显卡）。将巨型 VLA 模型直接部署到端侧面临着延迟、带宽与能耗的三重矛盾。

因此，如何验证“轻量化”VLA 模型在端侧设备上的运行边界与性能极限，已成为当前学术界关注的重点。本项目的选题“端侧可部署的双臂操作算法”，旨在通过复现与测试，探究这一关键技术的可行性。

1.1.3 本项目的核心定位

作为大一年度项目，本项目不仅是一次科研探索，更是一次工程素养的启蒙。我们明确了以下定位：

1. **重基础，轻创新**：重点在于对现有前沿技术（State-of-the-Art）的理解、复现与验证，而非盲目追求提出新算法。
2. **验证性体验为主**：利用开源社区提供的成熟模型（如 SmolVLA）和仿真平台（RoboTwin 2.0），进行“验证性体验”。
3. **过程导向**：强调在配置环境、阅读代码、分析数据过程中的学习积累，无论最终模型效果如何，过程文档本身即是重要成果。

1.2 国内外研究现状分析

1.2.1 视觉-语言-动作（VLA）模型的发展脉络

VLA 模型的研究经历了从专用小模型到通用大模型的演进。早期的 RT-1 等模型展示了模仿学习的潜

力 6。随后的 RT-2 更是创造性地将视觉-语言模型（VLM）与机器人动作数据进行联合微调。

为了解决部署难题，学术界开始探索“高效 VLA”。SmolVLA 是这一方向的代表，它通过精巧的架构设计（如跳过 VLM 的中间层），构建了一个轻量化模型，旨在实现端侧的高效推理。

1.2.2 仿真技术与 Sim-to-Real 的桥梁

数据是训练 VLA 模型的燃料。RoboTwin 2.0 代表了仿真技术的最新高度，它通过自动化代码生成和极致的域随机化（Domain Randomization），能够生成海量的合成数据，帮助模型适应现实世界的复杂性。

（二）项目研究内容及实施方案

2.1 理论基础构建

- **计算机视觉入门**：以斯坦福 CS231n 课程为大纲，学习卷积神经网络（CNN）、Transformer 架构及注意力机制，理解图像如何转化为机器可理解的特征。
- **Linux 与 Python 工具链**：学习 Ubuntu 系统的基本操作、Conda 环境管理、以及 Git 版本控制，建立规范的开发习惯。

2.2 仿真环境搭建与探索

- **RoboTwin 2.0 部署**：在本地或云端服务器上配置 RoboTwin 仿真环境，解决依赖冲突，实现仿真器的成功运行。
- **数据生成体验**：利用 RoboTwin 提供的脚本，尝试生成少量的双臂操作演示数据，并编写脚本对数据格式进行可视化分析，直观理解“机器人数据”的构成。

2.3 算法复现与验证

- **SmolVLA 模型跑通**：基于 Hugging Face 的 LeRobot 框架，下载并加载 SmolVLA 的预训练权重 [11]。
- **推理性能测试**：在现有硬件条件下（如个人笔记本），运行模型的推理代码，记录显存占用、推理延迟等关键指标，分析其是否真正满足“端侧部署”的要求。
- **（选做）简单微调**：若时间和算力允许，尝试使用少量生成的数据对模型进行微调，观察损失函数的变化。

（三）进度安排

我们将整个周期划分为四个阶段，每个阶段都设有“基础目标”与“挑战目标”。

第一阶段：知识储备与环境热身期（第 1-4 个月）

- **核心任务**：建立对深度学习和 Linux 系统的基本认知，克服“代码恐惧症”。
- **具体安排**：
  1. **理论学习（轻松模式）**：
     - 观看李宏毅《机器学习》或斯坦福 CS231n 课程的前几节核心视频（如神经网络简介、CNN 基础）。
     - **产出**：每人整理一份简单的学习笔记（Markdown 格式），记录核心概念即可。
  2. **工具上手（基础模式）**：
     - 安装 Anaconda，学会创建和激活虚拟环境。
     - 在 Windows 子系统（WSL）或虚拟机中练习 Linux 基本命令（ls, cd, mkdir 等）。
     - **产出**：一张配置好环境的终端截图。

第二阶段：仿真平台搭建与体验期（第 5-7 个月）

- **核心任务**：让仿真器“动起来”，体验机器人的数字孪生世界。
- **具体安排**：
  1. **环境配置（攻坚战）**：
     - 尝试按照 RoboTwin 官方文档配置仿真环境。
     - *注：此阶段极易遇到报错，遇到无法解决的问题可记录下来，作为“技术难点分析”写入报告，无需强求完美解决。*
  2. **Demo 运行（体验）**：
     - 运行官方提供的示例脚本（Run Demo），观察双臂机器人在屏幕上的运动。
     - **产出**：录制一段仿真器运行的录屏视频（哪怕只有几秒钟）。
  3. **数据初探**：
     - 尝试生成 1-2 条数据，查看生成的文件大小和格式。

第三阶段：算法验证与性能评估期（第 8-10 个月）

- **核心任务**：加载模型，看看它在我们的电脑上跑得有多快（或多慢）。
- **具体安排**：
  1. **模型加载**：
     - 使用 LeRobot 库下载 SmolVLA 的预训练模型。
  2. **推理测试（核心实验）**：
     - 编写一个最简单的 Python 脚本，输入一张图片，让模型输出结果。
     - **产出**：记录模型运行时的显存占用（截图任务管理器）和耗时（Print 时间戳）。
  3. **可行性分析**：
     - 根据测试结果，分析该模型是否适合在普通电脑上运行。如果跑不动或者报错，直接分析“为什么跑不动”，这也是极具价值的结论。

第四阶段：成果汇总与结题准备期（第 11-12 个月）

- **核心任务**：将之前的截图、笔记和录屏包装成高大上的结题报告。
- **具体安排**：
  1. **撰写报告**：汇总前三个阶段的“实验记录”和“故障分析”。
  2. **视频剪辑**：将仿真录屏简单剪辑，配上背景音乐，作为结题展示素材。
  3. **PPT 制作**：制作结题答辩 PPT，重点展示我们“探索过”、“尝试过”的路径。

（四）中期及结题预期目标（即中期检查和结题验收时考核的依据）

4.1 中期检查预期目标

(主要侧重于“学了什么”和“装了什么”)

1. **基础达标项（必须完成）**：
   - **学习报告**：提交一份《深度学习与机器人基础学习调研报告》，包含对 VLA 模型、Transformer 架构的通俗理解（可引用参考文献）。
   - **环境部署记录**：提交一份包含 Linux 环境配置、Conda 环境搭建过程的图文记录（Log），证明我们已经搭建好了实验台。
   - **文献综述**：对 RoboTwin 和 SmolVLA 两篇核心论文进行简单的中文摘要翻译和原理解读。
2. **进阶加分项（视情况而定）**：
   - 成功运行 RoboTwin 的官方演示代码，并提供截图。

- 完成 CS231n 课程的第一个编程作业（Assignment 1）。

4.2 结题验收预期目标

(主要侧重于“试了什么”和“结论是什么”)

1. **基础达标项（必须完成——轻松结题)**：
   - **《端侧部署可行性分析报告》**：这是核心成果。详细记录我们在普通硬件上尝试运行 SmolVLA 模型的过程。如果运行成功，记录性能数据；**如果运行失败或卡顿，详细分析原因（如显存不足、算力不够），并得出“当前轻量化模型在低成本端侧设备上部署仍具挑战”的科学结论。**
   - **技术避坑指南**：整理一份《机器人开发环境配置踩坑记录》，列出我们在配置 Ubuntu、CUDA、Python 库时遇到的错误及解决方法（或尝试过的无效方法）。
   - **演示视频**：提交一段 RoboTwin 仿真环境的运行录屏，或者 SmolVLA 模型加载过程的录屏，证明我们确实进行了实验操作。
2. **进阶加分项（视情况而定——展示实力)**：
   - **代码仓库**：在 GitHub 上上传我们调试过的脚本，并附带中文注释。
   - **实机/仿真演示**：在仿真环境中，让机械臂成功完成一次简单的抓取动作（Success Rate > 0）。
   - **对比评测**：对比不同模型（如 SmolVLA vs RT-1）在推理速度上的量化差异图表。

我们的结题依据以“完整的探索过程记录”和“基于实验事实的分析报告”作为考核核心。无论实验结果是成功还是失败，只要有详实的记录和科学的分析，即符合结题要求。

（五）经费使用计划

序号	项目名称	预算金额（元）	测算依据与说明
1	**数据存储设备**	800	购买移动硬盘（SSD），用于备份 RoboTwin 资产库和环境镜像，方便成员间拷贝资料。
2	**算力租赁**	1,000	预留资金。租赁 AutoDL、阿里云等平台的按时计费 GPU 进行仿真。
总计		**1,800**	

（六）主要参考文献（参考文献书写顺序：序号 作者.文章名.学术刊物名.年，卷（期）：引用起止页.）

[1] Chen T, Chen Z, Chen B, Cai Z, Liu Y, Liang Q, Li Z, Lin X, Ge Y, Gu Z, Deng W, Guo Y, Nian T, Xie X, Chen Q, Su K, Xu T, Hu M, Gao H, Wang K, Liang Z, Qin Y, Yang X, Luo P, Mu Y. RoboTwin 2.0: A Scalable Data Generator and Benchmark with Strong Domain Randomization for Robust Bimanual Robotic Manipulation. arXiv preprint arXiv:2506.18088v1 [cs.RO]. 2025.

[2] Capuano C, Kooijmans P, Palma S, Zoutine A, Aractingi M, Pascal C, Russi M, Marafioti A, Alibert S, Cord M, Wolf T, Cadene R. SmolVLA: A vision-language-action model for affordable and efficient robotics. arXiv preprint. 2025.

[3] Levine S, et al. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. arXiv preprint arXiv:2005.01643. 2020.

[4] Brohan A, et al. Rt-1: Robotics transformer for real-world control at scale. arXiv preprint arXiv:2212.06817. 2022.

[5] Brohan A, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic control. arXiv preprint arXiv:2307.15818. 2023.

[6] Kim M J, et al. OpenVLA: An open-source vision-language-action model. arXiv preprint arXiv:2406.09246. 2024.

[7] Mu Y, et al. RoboTwin: Dual-arm robot benchmark with generative digital twins. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2025.